

Qualidade de Audiência — Diagnóstico e Sinal Diário

Sistema Bring Data · Cliente DevClub · maio/2026

Sumário executivo

Investigação para responder operacionalmente: **a audiência que está chegando ao lançamento atual sinaliza bom faturamento, considerando apenas o público?** Três abordagens metodológicas foram testadas; a vencedora foi integrada ao endpoint `/monitoring/daily-check` em produção.

Achados-chave:

- **Sinal univariado de features ($P(\text{target}|\text{valor})$) descartado** — MAPE 43% em receita, Pearson 0.30 com ROAS. Detecta drift de mix mas não prediz absolutos.
- **Backtest do RF** (LF52 + LF53 first peak, OOS): Challenger abr28 com lift D10 de 1.8–2.2× vs Champion jan30 de 1.4×. Calibração de ambos ~60× off (score é rank, não probabilidade absoluta).
- **Sinal escolhido:** %D9-D10 e score médio do Challenger no LF atual comparados ao baseline pré-computado dos Top5 ROAS realized (LF40, LF41, LF45, LF50, LF53).
- **LF54 e DEV20:** ambos **DENTRO do padrão histórico** de bons lançamentos. DEV20 inclusive sinaliza ligeiramente acima (+3pp em D9-D10).

Resultado em produção (11/05/2026)

Revisão smart-ads-api-00439-fir em 100% do tráfego. Daily-check emite o bloco `audience_quality_signal` todo dia comparando o LF ativo vs baseline. Hoje: LF54 (n=5.532 leads) DENTRO do padrão, $\Delta\%D9-D10 = +1.8pp$, $\Delta\text{score} = +0.3\%$.

1. Pergunta-objeto

O sistema Bring Data já fornece o score do modelo (Random Forest) por lead. O score é usado para enviar eventos qualificados ao Meta (CAPI) e para o forecast de faturamento que existe no endpoint de monitoramento.

A pergunta operacional desta investigação é diferente: **tirando o score do modelo, a composição da audiência atual (gênero, idade, ocupação, faixa salarial, etc.) está sinalizando faturamento bom ou ruim?** A motivação é construir um sinal secundário que possa servir de orientação durante o lançamento, e que complemente o forecast já existente.

2. Audiência usada

Dois pools de dados são usados ao longo do estudo:

2.1 Pool de referência — Top5 ROAS realized

Cinco lançamentos cujo ROAS realizado (cobrado pelo cliente, descontados cancelamentos e ajustando TMB para 1/12 do ticket) foi mais alto entre todos os 16 ciclos cobertos pelo histórico (dez/2025 a abr/2026).

Lançamento	Período de captação	Período de vendas	ROAS realized	Leads
LF40	25/11/2025 — 02/12/2025	08/12 — 14/12/2025	3.40	3.999
LF41	02/12/2025 — 08/12/2025	15/12 — 21/12/2025	3.97	2.464
LF45	03/02/2026 — 23/02/2026	02/03 — 08/03/2026	3.25	15.325
LF50	24/03/2026 — 29/03/2026	01/04 — 06/04/2026	3.11	9.122
LF53*	13/04/2026 — 20/04/2026	27/04 — 03/05/2026	4.54	10.058

* LF53 — usou subset 'first peak' (primeiros 3 dias de venda) para isolar o produto principal do upsell. ROAS de 4.54 considera só o primeiro pico.

Total do pool: 40.968 leads. Pool definido após investigação comparativa entre 10 candidatos de referência (Top5 ROAS atual, ROAS realized com/sem outliers BF, interseção, mediana, etc.) — Top5 ROAS realized foi o de maior poder discriminante na correlação Spearman expected_conv × roas_realized das demais LFs (corr +0.66).

2.2 Pool de avaliação — LF atual + sanity

LF	Estado	Captação	Vendas	Leads (em 11/05)
LF54	Em curso	05/05 — 11/05/2026	18/05 — 24/05/2026	5.532
DEV20	Cap encerrado	21/04 — 04/05/2026	11/05 — 17/05/2026	29.298
LF52*	Sanity check	07/04 — 12/04/2026	17/04 — 24/04/2026	9.391

* LF52 — usado apenas como sanity check da metodologia. ROAS realized 2.46 (decente, não excepcional). Esperamos que fique 'dentro do padrão' levemente abaixo.

3. Features categóricas analisadas

Nove perguntas categóricas da pesquisa de captação são usadas em todas as análises:

Feature	Valores
1. O seu gênero	Masculino / Feminino
2. Qual a sua idade	<18, 18-24, 25-34, 35-44, 45-54, 55+

3. O que você faz atualmente	CLT, Autônomo, Estudante, Sem trabalho/estudo
4. Atualmente, qual a sua faixa salarial	6 faixas, "sem renda" → ">R\$15k"
5. Você possui cartão de crédito	Sim / Não
6. O que mais quer ver no evento	Programação / Mentoria / Outros
7. Tem computador/notebook	Sim / Não
8. Já estudou programação	Sim / Não
9. Pretende fazer faculdade	Sim / Não

4. Metodologia — três abordagens testadas

4.1 Abordagem A — Sinal univariado $P(\text{target}=1|\text{valor})$ — descartada

Para cada feature $\times$ valor, calcular $P(\text{target}=1|\text{valor})$ no pool de referência via Empirical Bayes ($\text{prior}_n=5$). Combinar por feature via Naive Bayes log-odds e prever conversão esperada do LF alvo. Multiplicar por ticket médio realizado para obter receita prevista.

Backtest (10 LFs fora da referência): MAPE 43% em receita, MAPE 43% em ROAS, Pearson 0.30 com ROAS, acurácia direcional 60% (apenas 10pp acima do chute). Conclusão: a metodologia univariada não prevê faturamento absoluto. **Detecta drift de mix mas não substitui o modelo.** Razão: independência assumida entre 9 features subestima interações multivariadas que o RF captura.

4.2 Abordagem B — Re-scorear com o Random Forest existente — adotada

Em vez de inventar uma nova métrica, usar o próprio modelo Random Forest do sistema. Para o pool de referência e o LF atual, scorear todos os leads com o mesmo modelo, calcular percentual de leads em D9-D10 e score médio. Comparar.

Esta abordagem captura as **interações multivariadas** que a univariada perde. O Random Forest, treinado com 60 features pós-encoding, modela combinações como 'homem, 18-24, CLT, com cartão' que individualmente são fracas mas juntas são preditivas.

4.3 Abordagem C — Usar Lead.decil já gravado em produção — descartada

Consultar o decil que produção atribuiu via Cloud Run a cada lead, sem re-scorear. Vantagem: simplicidade total. **Descartada** porque os leads dos lançamentos históricos foram escorados por **versões diferentes do código e modelo**: o Champion jan30 esteve ativo, mas o patch DT-12 (que corrigia idade/salário cegos via encoding overrides) só entrou em 02/05/2026. Comparar Lead.leadScore antigo com Lead.leadScore atual mistura cobertura de bug.

Decisão metodológica chave

Re-scorear TUDO agora (baseline histórico + LF atual) com o mesmo código e o mesmo modelo. Self-consistent por construção. Não depender de fotografias antigas do score salvas em produção.

5. Backtest do Random Forest — Champion vs Challenger

Antes de adotar o score do RF como sinal, validamos sua capacidade preditiva em lançamentos out-of-sample para ambos os modelos ativos. Dois modelos vivem no A/B test atual:

Modelo	Run ID	Treino até	Roteamento
Champion jan30	d51757f5...	04/11/2025	Default (sem UTM HQLB)
Challenger abr28	5d158f0a...	08/04/2026	utm_campaign "PIXEL NOVO API" ou URL ml-parabens-psq-devf

LFs out-of-sample escolhidos: LF52 (cap 07-12/04, n=9.391 leads) e LF53 first peak (cap 13-20/04, n=10.054). LF52 é OOS para o Champion (treino até 04/11) e parcial OOS para o Challenger (3 dias dentro do treino). LF53fp é 100% OOS para ambos.

5.1 Discriminação (lift por decil)

Métrica	LF52	LF53fp
Lift D10 — Champion jan30	1.39×	1.37×
Lift D10 — Challenger abr28	1.81×	2.19×
Concentração top30 — Champion (D8-D10 = 60% leads)	81%	68%
Concentração top30 — Challenger (D8-D10 = 34% leads)	61%	53%
ROAS top30 offline — Champion	3.26	1.80
ROAS top30 offline — Challenger	4.31	2.35

Leitura: em ambos os LFs OOS, o Challenger discrimina 30-60% melhor que o Champion (lift D10 mais alto). Em LF53fp — 100% out-of-sample do Challenger — o lift D10 atinge 2.19×, o que significa que a taxa de conversão real do D10 é **2.19× a baseline**. Esse é o sinal preditivo que importa para o Meta otimizar audiência.

5.2 Calibração (score absoluto)

Métrica	Champion jan30 (LF52)	Challenger abr28 (LF52)
Score médio do modelo	0.387	0.417
Taxa real de conversão	0.69%	0.69%
calib_ratio (score / taxa real)	56×	60×

Diferença crítica — discriminação ≠ calibração

O score do RF está **56-60× a taxa real** de conversão. Isso não é bug — é estrutural: o modelo foi treinado com class balancing, e predict_proba devolve um score de **ranking**, não uma probabilidade calibrada. Por isso o "Champion prevê faturamento maior do que o real" é literal, mas não é erro do modelo — é decisão de design. **$\Sigma(\text{score}) \times \text{ticket}$ NÃO é receita prevista útil**. Para prever faturamento absoluto, seria preciso recalibrar via Platt scaling ou isotonic regression (item de backlog). Para o sinal de drift, basta usar rank (% leads em decis altos), que é o que esta investigação faz.

6. Sinal final — qualidade de audiência LF54 e DEV20

Aplicamos a abordagem B (re-scorear com Challenger) sobre os 5 LFs do pool de referência e sobre LF54 + DEV20. Calculamos para cada LF o score médio, %D10, %D9-D10 e %D8-D10. O baseline ponderado pelo volume de leads do pool é a régua de comparação.

6.1 Métricas por LF

LF	n leads	score médio	%D10	%D9-D10	%D8-D10
★ LF40	3.986	0.4302	11.5%	23.5%	36.4%
★ LF41	3.984	0.4379	11.8%	26.5%	34.5%
★ LF45	8.531	0.4559	17.1%	30.5%	43.1%
★ LF50	9.122	0.4209	12.2%	23.7%	35.0%
★ LF53fp	10.054	0.4159	11.6%	23.3%	34.0%
Baseline (pond.)	35.677	0.4308	13.1%	25.5%	36.7%
◆ LF54 (atual)	5.532	0.4319	13.9%	27.3%	38.9%
◆ DEV20 (cap fim.)	29.298	0.4401	15.7%	28.7%	40.6%
· LF52 (sanity)	9.391	0.4169	12.1%	23.5%	34.4%

★ = LFs do pool de referência (Top5 ROAS realized). ◆ = LFs avaliados (LF54 em curso, DEV20 com captação encerrada). · = sanity check.

6.2 Δ vs baseline (régua única — Challenger abr28)

LF	Δscore	Δ%D10 (pp)	Δ%D9-D10 (pp)	Sinal
LF54	+0.3%	+0.8	+1.8	DENTRO do padrão
DEV20	+2.2%	+2.7	+3.2	DENTRO (ligeiramente acima)
LF52	-3.2%	-1.0	-2.0	DENTRO (ligeiramente abaixo)

Conclusão prática

LF54 (5.532 leads parcial) e DEV20 (29.298 leads, captação encerrada) têm audiência DENTRO do padrão histórico de bons lançamentos. DEV20 inclusive sinaliza ligeiramente acima (+3.2pp em D9-D10, +2.2% em score médio). Não há indício de degradação de público. Se houver problema, está em outro lugar (criativo, taxa de conversão da página, mix de produto, sazonalidade).

Sanity check passou: LF52, cujo ROAS realized foi 2.46 (decente mas não top), ficou levemente abaixo do baseline (-2.0pp em D9-D10) — alinhado com sua performance histórica intermediária. Isso valida que a métrica é estável e discriminante.

7. Integração no endpoint de monitoring

O sinal foi integrado ao `/monitoring/daily-check/railway` do Cloud Run. Toda execução diária do monitoramento (via Cloud Scheduler) passa a emitir um bloco `audience_quality_signal` que aparece junto com os demais alertas no digest.

7.1 Arquitetura

Chain idêntica à produção: a função `_check_audience_quality_signal` chama `LeadScoringPipeline.run` com tempfile CSV e `predictor_override=Challenger` — exatamente o que o webhook de produção faz em `api/app.py:345` (batch) e `:959` (síncrono). Reusa o `LeadScoringPipeline` já carregado no startup via injeção de dependência (orchestrator → `DataQualityMonitor`).

Baseline pré-computado em `configs/reference_audience_profiles/devclub_quality_signal.json` com as métricas do Top5 ROAS realized. Re-gerar quando trocar de modelo Challenger.

7.2 Severidade do alerta emitido

Condição	Severity	Sinal
$\Delta\%D9-D10 \leq -5pp$ OU $\Delta score \leq -10\%$	HIGH	Audiência ABAIXO do padrão (alerta)
$\Delta\%D9-D10 \leq -3pp$ OU $\Delta score \leq -5\%$	MEDIUM	Levemente abaixo (atenção)
$\Delta\%D9-D10 \geq +3pp$ E $\Delta score \geq +5\%$	LOW	ACIMA do padrão (informativo)
Faixa neutra entre os limites	LOW	DENTRO do padrão (informativo)

7.3 Deploy

Revisão Cloud Run `smart-ads-api-00439-fir` deployed em 11/05/2026 10:44 BRT, promovida para 100% do tráfego após smoke test e validação do bloco em chamada direta na revisão canary.

8. Limitações conhecidas

- 1. Score absoluto não-calibrado.** $\text{calib_ratio} \sim 60\times$ — para predição de R\$ absoluto, seria necessária recalibração via Platt scaling ou isotonic regression. Item de backlog. Para o sinal de drift adotado, basta o rank, então não é bloqueador.
- 2. Sinal é premissa, não previsão.** Audiência com composição similar aos bons LFs (medida pelo modelo) *sugere* faturamento similar. Pode falhar se o Meta entregar leads bem-ranqueados pelo modelo mas com criativo/fluxo/landing page ruim. O sinal não substitui o forecast de receita do endpoint, apenas o complementa.
- 3. Paridade backtest vs Lead.leadScore: 23%.** Comparando re-score atual com o valor salvo pelo Cloud Run em produção, a coincidência exata é de apenas 23% (decil bate em 52%). Causa raiz não identificada (testamos round-trip xlsx vs csv, race condition em createdAt vs updatedAt, mudanças de schema). Possíveis explicações: estado dinâmico do pesquisa jsonb (parcial no momento do score em prod, completo agora), versões de código diferentes entre score em prod e re-score agora. Mitigação adotada: **não usar Lead.leadScore — re-scorear tudo agora com mesma chain**, garantindo self-consistency.
- 4. Challenger parcialmente in-sample para LF45/LF50 do baseline.** O Challenger abr28 teve cutoff em 08/04/2026 — LF45 e LF50 estão dentro do training+test do Challenger. Apenas LF53fp é 100% OOS. Para o baseline (régua de comparação) isso não é problema; para validar capacidade preditiva do modelo, usei LF53fp como OOS puro.
- 5. Spread baixo entre os deltas observados.** LF52 (-2pp), LF54 (+1.8pp), DEV20 (+3.2pp). O sinal de drift dentro do esperado tem amplitude pequena — não classifica em "ótimo / médio / ruim". Está dizendo apenas: "audiência similar aos bons" ou "diferente". Para classificações finas, seria preciso baseline maior + threshold calibrado em mais lançamentos.

9. Próximos passos / backlog

- 1. Recalibração do score do RF.** Treinar uma camada de calibração isotônica num holdout pós-train (~30min de trabalho). Salvar a curva no MLflow junto com o modelo. Output: score do RF passa a ser uma probabilidade calibrada ($\Sigma(\text{score}) \approx \text{buyers reais}$). Não muda nada no rank (lift D10 idêntico), mas resolve o viés sistemático do revenue forecast (que hoje tem patches heurísticos).
- 2. Acompanhar LF54 até o fim do ciclo.** $\Delta\%D9-D10 = +1.8\text{pp}$ parcial; o sinal pode se mover quando a captação fechar (11/05). O daily-check vai mostrar o valor atualizado diariamente.
- 3. Re-validar quando próximo Champion entrar.** O backtest precisa ser refeito com modelo novo. Baseline JSON pré-computado também precisa ser regerado.
- 4. Investigar causa raiz da divergência backtest vs Lead.leadScore.** 77% de divergência indica algo estrutural (estado dinâmico, race condition). Não bloqueia o sinal porque já adotamos self-consistency, mas vale entender pra futuras integrações que dependam de Lead.leadScore.