

Teste A/B Champion vs Challenger — DEV20

28/04/2026 · Lançamento DEV20 (cap 21/04 → 04/05, vendas 11/05 → 17/05)

Champion (A) = jan30 — modelo em produção desde 30/01/2026 | **Challenger (B) = abr28** — candidato treinado em 28/04/2026

Sumário executivo

O Champion A entrega ROAS médio de **5,3×** ao longo de 7 lançamentos consecutivos (LF45–LF51).

O Challenger B foi treinado com dataset 1,8× maior (201 mil leads vs 110 mil). Em testes offline sobre 186 vendas reais (LF51, LF52, LF53), **B separa compradores de não-compradores cerca de 2,7× melhor** que A no decil mais alto.

Antes de promover B a Champion, é necessário validar em produção real. Propomos teste A/B no DEV20 com **R\$ 72k (35% do orçamento restante)** alocado numa campanha B, mantendo as campanhas A com os R\$ 133k restantes.

Leitura final: **22–25/05/2026** após carrinho fechar e parcelas TMB efetivarem.

1. Por que considerar substituir o Champion A

O que A entrega hoje

Lançamento	ROAS	Top■3 decis (D8+D9+D10) capturam
LF45	7,70×	75% das vendas
LF46	5,73×	77% das vendas
LF47	5,75×	73% das vendas
LF48	3,63×	67% das vendas
LF49	5,39×	38% (anomalia documentada)
LF50	5,06×	69% das vendas
LF51	3,85×	61% das vendas
Média	5,3×	66% das vendas

Os 30% de leads classificados nos top 3 decis pelo Champion A capturam, em média, 66% das vendas do lançamento.

Por que reavaliar

- Saturação no decil mais alto.** A hoje classifica ~33% dos leads como D10 (esperado pela calibração do treino: 10%).
- Treino defasado.** A foi treinado com dados até novembro de 2025 — não viu nenhum lançamento de 2026.
- Volume de dados disponíveis cresceu.** Dataset disponível hoje é quase 2× maior que o usado no treino de A.

O que B traz de diferente

Característica	Champion A (jan30)	Challenger B (abr28)
Data de treino	30/01/2026	28/04/2026
Total de leads no dataset	110.505	201.547
Janela temporal coberta	mar/2025 → nov/2025	fev/2025 → abr/2026
Fontes de venda	Guru	Guru + Hotmart
Fontes de lead	Sheets	Sheets + Railway
Correção de feedback loop	Não	Sim (importance weighting do grupo controle)

2. Performance comparativa em testes offline

Avaliamos os dois modelos nos lançamentos LF51 (parcial), LF52 e LF53 — período em que **nenhum dos dois** havia visto os leads no treino. Total: **186 vendas reais matched**.

Quanto leads dos top decis convertem acima da média do lançamento

Métrica	Challenger B	Champion A
Lead D10 → converte X% acima da média	+102%	+40%
Lead D9 → converte X% acima da média	+41%	+18%
Lead D9+D10 (top 20%) → converte X% acima da média	+72%	+33%

Quando B classifica um lead como D10, esse grupo converte 102% acima da média do lançamento. Quando A classifica o mesmo, o grupo converte 40% acima.

ROAS observado offline (top decis)

Métrica	Challenger B	Champion A
ROAS dos top 30% leads (top 3 decis)	2,29×	1,84×
ROAS dos top 50% leads (top 5 decis)	2,00×	1,74×
ROAS de toda a base (controle)	1,50×	1,50×

ROAS de toda a base é igual (mesmo dataset). A diferença aparece quando filtramos por decis altos.

3. Validação técnica do pipeline


A produção hoje roda numa versão antiga do código (commit "rollback" de 05/03/2026). Para servir B em produção, precisamos voltar a usar a versão atual do código.

Pegamos 5.000 leads reais e rodamos o Champion A em ambas as versões do código. Resultados:

Métrica	Resultado
Score idêntico nas duas versões (diferença <0,001)	96% dos leads
Mesmo decil atribuído pelas duas versões	98,3% dos leads

Em 100 leads, ~98 receberiam exatamente o mesmo decil em ambas as versões. Os ~2 restantes ficariam deslocados em ± 1 decil. Magnitude pequena, sem impacto material no ROAS agregado.

4. Como o teste vai funcionar



Cada modelo emite seu próprio evento ao Meta. Cada campanha é configurada para otimizar pelo seu evento correspondente. Vendas reais são medidas externamente (via plataformas Hotmart/Guru/Asaas) — a métrica de ROAS por modelo é calculada por nós, não pelo Meta.

5. Investimento necessário

Para concluir com segurança que "B é melhor que A", precisamos observar um número mínimo de vendas atribuídas a cada modelo. Com pouco investimento em B, o sinal não consegue ser distinguido do ruído da amostra pequena.

Cenário	% budget B	R\$ B	Detecta diferença de...
Mínimo direcional	15%	R\$ 31k	apenas >40% (só sinais grandes)
Conservador	25%	R\$ 51k	>30%
Moderado (recomendado)	35%	R\$ 72k	>25%
Equilibrado	50%	R\$ 102k	>18%

Recomendação: cenário moderado (R\$ 72k em B). Detecta diferenças de ROAS $\geq 25\%$ — exatamente o range esperado dado os testes offline. A continua com R\$ 133k (65% do orçamento) — ROAS atual protegido.

